Inteligencia Artificial

Dr. Víctor Uc Cetima

Perceptrón multicapa

Ejercicio 1: Más capas en el perceptrón multicapa (Iris)

Octavio Jacome Mata

Contexto

En Perceptrón multicapa/Notebooks/ hay dos notebooks que resuelven el mismo problema: clasificar las 3 especies del conjunto Iris (4 atributos: sépalo/pétalo en largo y ancho). Ambas redes son un MLP con activación sigmoide, error MSE, SGD con ($\theta = 0.03$) y 500 épocas. En la notebook 01, ($4 \times 3 \times 3$) significa: 4 entradas, una capa oculta de 3 neuronas y 3 neuronas de salida (una por clase). En Keras es lo mismo: dos Dense(3) (la primera con input_shape=(4,)).

Reporte

¿Baja más el error al añadir dos capas, o se estancó / empeoró? ¿Igual en NumPy y en Keras?

Ambos enfoques **no** dan mejores resultados; de hecho, lo contrario, obteniendo puntuaciones un poco más bajas. Esto puede atribuirse al desvanecimiento del gradiente: es una tarea ya separable con facilidad; añadir dimensionalidad con la misma función de activación evita que las primeras capas aprendan.

¿Las curvas de la notebook 01 y de Keras se parecen con la misma topología? Si no, ¿qué diferencias de implementación podrían explicarlo (orden de los datos, inicialización, vectorización, etc.)?

Las curvas no se parecen: el perceptrón multicapa al principio parece no aprender, manteniendo un error alto, pero casi a mitad del entrenamiento comienza a bajar abruptamente para finalmente converger al final; el enfoque Keras devuelve una curva de aprendizaje más estable durante todo el entrenamiento. Este comportamiento puede deberse al tamaño de cada paso de actualización: para el MLP es por cada muestra, mientras que para Keras es en lotes. También puede deberse a la precisión numérica de cada método, ya que la implementación 'a mano' utiliza la CPU, mientras que Keras tiene una optimización para la GPU.

Con sigmoides apiladas y MSE, ¿tiene sentido que una red más profunda no aprenda mejor en Iris? Relaciónalo con lo que viste en las gráficas.

Si lo tiene, ya que podemos estar ante un caso de desvanecimiento del gradiente. Antes estudiamos que la función de activación sigmoide presenta este problema en redes cada vez más profundas, donde solo las últimas capas aprenden y el error no se propaga a las primeras capas. Esto se puede ver mejor en las gráficas del MLP, que muestran un menor aprendizaje al principio del entrenamiento, signo de que la propagación del error no era suficiente al principio.