Inteligencia Artificial

Dr. Víctor Uc Cetima

Clustering K-medias

Ejercicio 1 — Separar los blobs y volver a elegir (k)

Octavio Jacome Mata

Contexto

La notebook `Clustering K-medias/Notebooks/01 K-medias.ipynb` (capítulo de Géron / *Hands-On ML*) entrena **k-means** de scikit-learn sobre nubes gaussianas y termina con segmentación de color de una foto.

La parte central genera 5 blobs, ajusta `KMeans(n_clusters=5, ...)` y después busca el (k) "bueno" con dos herramientas:

Herramienta	**Qué grafica**	**Lectura en la notebook original**
Codo (inercia J) vs (k)	`inertias` para (k = 1,. . . ,9)	El codo está en (k = 4), no en 5
Silueta	`silhouette_score` para (k = 2,. . . ,9)	(k = 4) se ve muy bien; (k = 5) también

Eso no es un bug: **tres blobs de la izquierda están casi pegados** (`std = 0.1` y centros en (x = -2.8)). K-means (y el código) los trata como un solo grupo.

En este ejercicio **sí vas a modificar código**, pero un cambio pequeño y local: **alejar esos blobs**. No toques `Clustering K-medias/project/`. Trabajas en Colab, sobre una copia de la notebook.

Reporte

En los datos de Géron, ¿por qué el codo "prefiere" ($k = 4$) si make_blobs usó 5 centros?

Esta respuesta se da por la proximidad entre los blobs. En general, el algoritmo 'no sabe' cuántos grupos hay, solo intenta agruparlos según densidad y distancia. Si hay datos que naturalmente están próximos, el algoritmo tiende a fusionarlos si eso minimiza mejor la inercia.

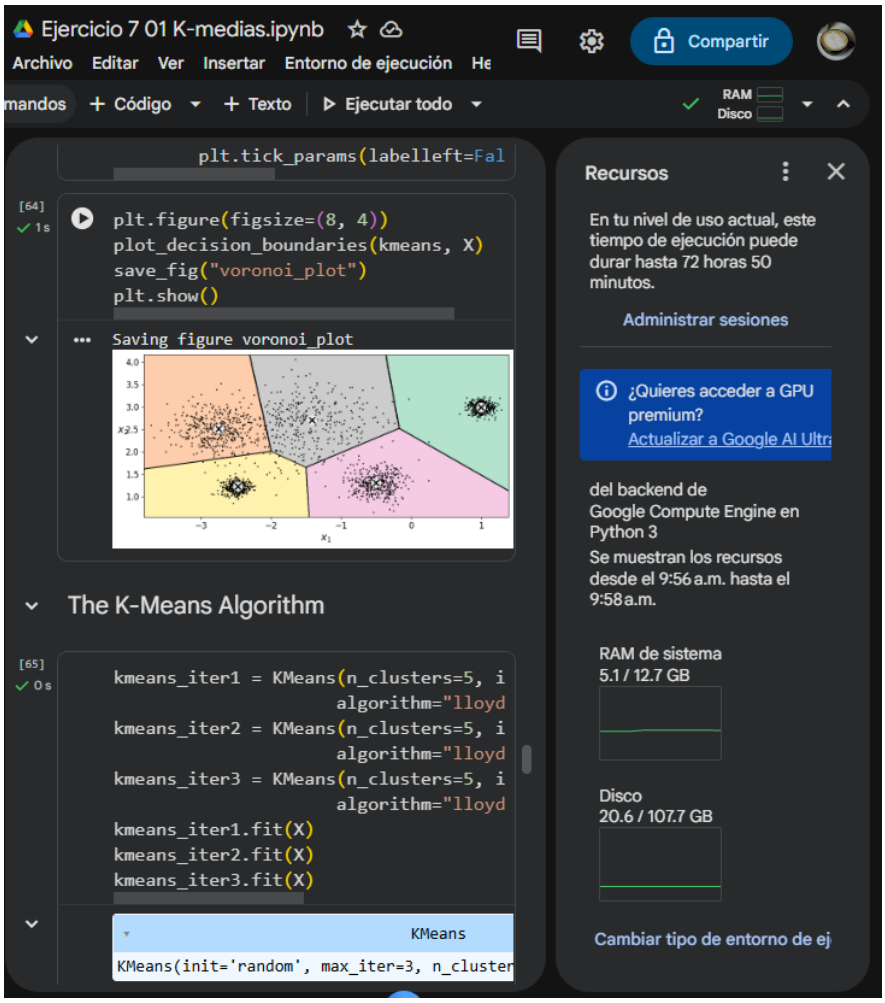
Con tus blobs separados, ¿el codo y la silueta coinciden en el mismo (k)? ¿Ese (k) es 5?

Si separamos los blobs, el codo y la silueta deberían coincidir en k $\bar{5}$, el mismo número que grupos reales. El algoritmo ya no tendría incentivo para fusionar blobs, porque separarlos reduciría la inercia significativamente. Pero esto solo se logra con una separación suficiente, ni muy poca, para no fusionar, ni demasiada, pues puede afectar la curva de inercia.

Si el codo sigue en 4, ¿qué te falta mover (distancia entre centros vs. blob_std)?

En realidad, es una combinación de ambas. Si el codo sigue en 4, aún hace falta separación relativa. Esto puede abordarse primero separando los centros, idealmente en las dos coordenadas del plano, pero si no es suficiente, significa que los grupos tienen una amplia cobertura, por lo que, como segundo paso, habría que ajustar su desviación estándar. Una regla práctica es que la distancia entre centros sea al menos 3-4 veces la *std*.

Evidencia de ejecución



Ejercución en Google Colab