Inteligencia Artificial

Dr. Víctor Uc Cetima

Q-learning

Ejercicio 1: Q-learning en Cliff Walking

Octavio Jacome Mata

Contexto

Cliff Walking es el ejemplo de control con diferencias temporales de Sutton y Barto. El agente camina por una cuadrícula. Cada paso cuesta -1. La fila inferior, entre la salida y la meta, es un acantilado: pisarlo cuesta -100. Con ϵ**-greedy** ($\epsilon = 0.1$), Q-learning aprende la política que va **junto al borde** del acantilado: es la más corta y, por tanto, la de mayor retorno.

Reporte

¿Por qué el camino de 13 pasos, pegado al acantilado, es óptimo?

Es el camino más óptimo porque el algoritmo está minimizando el coste de 'caminar' hasta la meta o, dicho de otro modo, maximizando el retorno. Aunque pareciera que no es el camino más seguro, dado que está al lado del acantilado, la política greedy óptima no elige movimientos que puedan hacer caer al agente.

¿Por qué la curva de entrenamiento queda por debajo de -13 aunque la política greedy ya sea óptima?

Esto es por la conducta 'exploratoria' de Q-learning. Aunque ya se haya descubierto la ruta óptima durante el entrenamiento, el algoritmo siempre asumirá un riesgo (ϵ) de descubrir otra alternativa, eligiendo una acción al azar con probabilidad ϵ. Por ello, la curva de entrenamiento nunca se mantiene estable; cada valle representa la acción aleatoria que tomó el agente.

En el paso que cae al acantilado, ¿cuál es s' en el backup de Q-learning, y por qué ese backup no trata el acantilado como estado terminal?

El siguiente estado después de caer al acantilado es el estado inicial ya que, para este agente, caer en el acantilado representa empezar de nuevo considerando la penalización de haber caído. De lo contrario, el algoritmo se rompería y probablemente adoptaría una política más conservadora respecto al acantilado.